GDIZ Maintenance
prédictive

Auteur Bill Yehouenou

Table des matières

1 Vue d'ensemble **2**

2 Données **2**

3 Du relevé à la prédiction **3**

3.1 Variables du modèle . . . 3

3.2 Cible . . . 3

3.3 Découpage dans le temps . . . 3

3.4 Modèle . . . 4

3.5 Mesure de la performance . . . 4

4 Registre et cycle de vie du modèle **4**

5 Service **5**

5.1 API . . . 5

5.2 Tableau de bord . . . 5

6 Suivi en production **5**

7 Limites **6**

Glossaire **6**

1 Vue d'ensemble

Le système tient en quatre couches : les *données* (simulées à partir de la météo réelle), le *modèle* (entraîné puis enregistré dans MLflow), le *service* (API et tableau de bord) et le *suivi* (performance réelle et dérive). Tout passe par une base DuckDB embarquée et un registre MLflow : il n'y a pas d'autre état partagé.

Dossier	Rôle
`simulation/`	Météo réelle, physique des machines, défaillances des capteurs, écriture dans DuckDB
`src/donnees.py`	Chargement, features glissantes, cible à 120 h, découpage dans le temps
`src/evaluation.py`	Métrique événementielle (pannes annoncées, fausses alertes, préavis) et bilan en FCFA
`src/train.py`	Entraînement, calibration, choix du seuil, enregistrement et promotion dans MLflow
`src/modele.py`	Modèle en service, cause probable (SHAP), scoring des 60 derniers jours
`src/metier.py`	Règles et coûts de l'atelier, indicateurs servis au tableau de bord
`src/drift.py`	Performance réelle récente et dérive des capteurs
`app/`, `web/`	API FastAPI et schémas ; tableau de bord HTML, CSS et JavaScript sans framework
`tests/`, `notebooks/`	Tests automatisés ; exploration des données et comparaison des modèles

TABLE 1. Organisation du code.

2 Données

Aucune donnée réelle de capteurs n'est disponible pour l'atelier de Glo-Djigbé : les données sont donc simulées, mais ancrées dans le réel. Le point de départ est la météo horaire observée sur le site en 2024 et 2025, téléchargée depuis Open-Meteo : température, humidité et pluie issues de la réanalyse ERA5, poussière désertique issue du service atmosphérique CAMS, qui capte les épisodes d'Harmattan de décembre à mars. Cette météo est ramenée au pas de 30 minutes, puis sert de décor commun aux 50 machines de l'atelier, réparties en trois gammes aux comportements différents : des machines rustiques plus sensibles à la poussière, des machines standard, et des machines de précision protégées par un onduleur mais plus sensibles aux variations de tension.

De l'extérieur, on passe à l'intérieur de l'atelier comme le ferait un bâtiment réel. La toiture en tôle transmet la chaleur avec environ trois heures de retard, les machines en marche ajoutent leur propre chaleur et une ventilation se déclenche au-delà de 38 °C. L'air réchauffé voit son humidité relative baisser, la poussière extérieure s'infiltre progressivement et s'ajoute aux fibres textiles soulevées par la production. Le rythme de l'usine suit trois équipes en 3×8, avec une relève moins productive et un arrêt complet le week-end. Le réseau électrique de la SBEE, enfin, connaît des délestages, plus fréquents aux heures de pointe et d'une heure environ, et une tension qui fléchit quand la charge augmente.

Chaque machine porte ensuite un état caché qui évolue pas à pas, comme sur une vraie ligne de production. L'outil s'use plus vite dans la poussière et sous une tension instable, la machine s'encrasse et dissipe moins bien sa chaleur, les roulements s'usent avec la vitesse. Cet état se lit indirectement dans les capteurs : la vibration augmente avec l'usure, la température avec l'encrassement. Cinq risques de panne se font concurrence, sur le modèle du jeu de référence AI4I 2020 : la rupture de l'outil à l'approche d'un seuil propre à chaque machine, la surchauffe soutenue, la surcharge mécanique, le choc électrique au retour du courant et une part d'aléatoire. Chaque panne immobilise la machine pour une réparation de durée réaliste et remplace le composant en cause ; des entretiens préventifs, plus probables sur une machine usée, remettent aussi les compteurs à zéro. Sur deux ans, l'atelier connaît 713 pannes.

Enfin, le modèle ne voit que ce qu'une usine verrait réellement. L'état caché n'est jamais exporté : seuls les capteurs, les conditions de l'atelier et les compteurs de maintenance (GMAO) le sont. Les capteurs eux-mêmes sont imparfaits, avec des paquets perdus (environ 1 % de valeurs manquantes), des valeurs figées et des dérives lentes. L'ensemble, reproductible grâce à une graine aléatoire fixe, forme 1,75 million de relevés écrits dans une base DuckDB. Ces mécanismes sont plausibles et calibrés avec soin, mais ils restent une simulation : les résultats du modèle devront être confirmés sur de vrais capteurs.

3 Du relevé à la prédiction

3.1 Variables du modèle

Le modèle voit 35 variables. Les statistiques glissantes sont calculées sur les *seuls relevés en marche* : le week-end, les capteurs tombent à zéro et feraient croire, le lundi matin, à une machine plus calme qu'elle ne l'est. Une même fonction calcule les variables pour l'entraînement, le scoring et l'API : une prédiction n'a besoin que des 24 dernières heures de la machine.

Groupe	Variables	Nombre
Gamme	`type_machine`	1
Mesures du relevé	capteurs de la machine, conditions de l'atelier et réseau électrique	11
Compteurs GMAO	heures depuis le changement d'outil, depuis la dernière intervention	2
Écart thermique	température du process moins température ambiante	1
Statistiques glissantes	pour la vibration, la température du process, l'écart thermique, le couple et la poussière : moyenne, maximum et écart-type sur 24 h, hausse sur 4 h	20
Total		**35**

TABLE 2. Variables d'entrée du modèle.

3.2 Cible

Un relevé est positif si une panne prévisible (TWF, OSF ou HDF) survient sur la machine dans les 120 heures qui suivent. Le modèle n'apprend et ne note que les relevés en marche : une machine arrêtée ne déclenche jamais d'alerte.

3.3 Découpage dans le temps

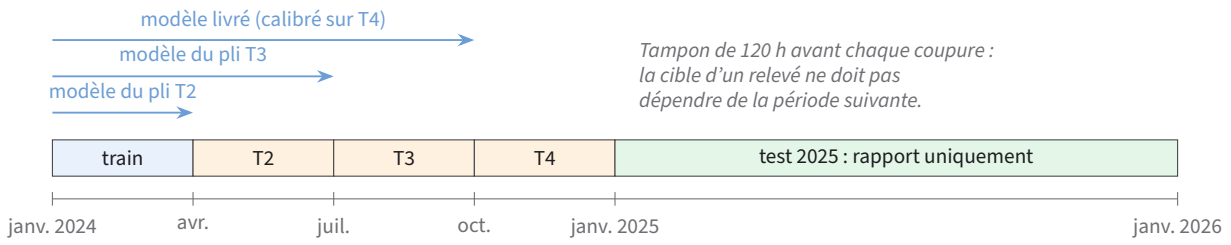


FIGURE 1. Chaque trimestre de validation est noté par un modèle entraîné sur ce qui le précède, pour comparer les modèles. Le modèle livré est calibré et seuillé sur T4 ; 2025 ne sert qu'au rapport.

Une machine sur cinq n'est jamais vue à l'entraînement : elle mesure la généralisation à une machine neuve.

3.4 Modèle

— **LightGBM**, retenu face à une régression logistique, un arbre de décision et HistGradientBoosting (`notebooks/1_comparaison_modeles.ipynb`) : les quatre se tiennent à moins de 1,5 écart-type, LightGBM est le plus rapide et SHAP l'explique exactement. Réglage volontairement contraint : 80 arbres de 7 feuilles, au moins 1 000 relevés par feuille ; un modèle plus libre apprend le train par cœur.

— **Calibration sigmoïde** sur la validation, appliquée aux log-odds : une probabilité de 10 % signifie qu'environ une machine sur dix tombe en panne dans les 5 jours.

— **Seuil d'alerte** : celui qui annonce le plus de pannes sans dépasser 0,2 fausse alerte par machine et par jour, choisi sur le dernier trimestre de validation. Il est enregistré avec le modèle : les deux ne peuvent pas diverger.

— **Cause probable** : les contributions SHAP sont regroupées en quatre familles physiques (usure et entretien, surchauffe, surcharge mécanique, environnement et réseau).

3.5 Mesure de la performance

Le système note chaque machine toutes les 30 minutes, mais un technicien ne se déplace qu'une fois pour une alerte qui dure : la mesure compte donc des *épisodes* d'alerte, redécoupés toutes les 24 h pour qu'alerter en permanence ne paie pas.

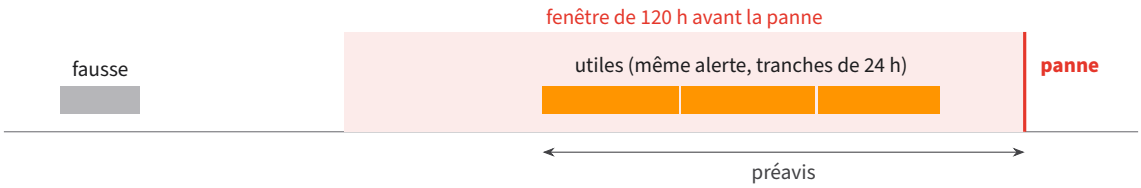


FIGURE 2. Une panne est annoncée si un épisode chevauche les 120 h qui la précèdent. Toutes les tranches de cette fenêtre lui reviennent ; le préavis part de la première. Un épisode rattaché à aucune panne est une fausse alerte.

Indicateur, modèle déployé	Valeur
Pannes prévisibles annoncées, validation 2024	82 %
Pannes prévisibles annoncées, test 2025 (283 pannes)	81 %
dont usure de l'outil / surchauffe / surcharge mécanique	100 / 71 / 66 %
Préavis médian	114 h
Épisodes d'alerte utiles	23 %
Fausses alertes par machine et par jour (budget 0,2)	0,18
Gain net 2025	8,1 M FCFA

TABLE 3. Performance du modèle déployé.

4 Registre et cycle de vie du modèle

Chaque entraînement enregistre dans MLflow le modèle calibré, ses hyperparamètres, son seuil exact et ses métriques. Le service ne charge jamais autre chose que l'alias `@champion` : un entraînement raté ne touche pas la production.

Le scoring écrit ensuite la probabilité de chaque relevé en marche des 60 derniers jours dans la table `predictions`, avec la cause probable du dernier relevé des machines en alerte.

5 Service

5.1 API

Méthode	Route	Rôle
POST	`/api/v1/predict`	Un relevé : probabilité de panne et alerte
POST	`/api/v1/predict/batch`	Plusieurs relevés en un appel au modèle
GET	`/api/v1/etat`	Statut actuel des 50 machines, risque et criticité
GET	`/api/v1/parc`	Indicateurs d'une période et de la précédente, coût des pannes
GET	`/api/v1/machines/{id}`	Fiche machine : santé, cause, contributions SHAP, capteurs
GET	`/api/v1/machines/{id}/risque`	Risque au pas de 2 h sur 30 jours
GET / POST	`/api/v1/info`, `/reload`	Version chargée ; rechargement du @champion

TABLE 4. Routes de l'API (documentation interactive sur `/docs`).

Une prédiction ajoute le relevé reçu aux 24 dernières heures de sa machine, calcule les variables avec le même code qu'à l'entraînement et répond en une trentaine de millisecondes.

5.2 Tableau de bord

Servi par la même application FastAPI, en HTML, CSS et JavaScript sans framework :

— **Parc** : indicateurs de la période (disponibilité, MTBF, coût des pannes, heures d'arrêt) comparés à la période précédente, plan de l'atelier, matrice risque × criticité qui dit quoi faire (agir, planifier, surveiller), pannes par gamme et par cause, coût par mois ;

— **Machine** : santé, risque à 5 jours, cause probable expliquée en une phrase, contributions SHAP, historique des pannes sur 12 mois, capteurs face aux limites du parc, courbe du risque sur 30 jours.

La criticité vient de la chaîne de production : une cardeuse (4 machines sur l'étape) pèse plus qu'un métier à tisser (24 machines). Le coût d'une panne compte les pièces, la production perdue et le technicien pendant la durée réelle de l'arrêt, et le tissu rebuté ; une panne annoncée devient un arrêt planifié de 2 h sans rebut.

6 Suivi en production

`make check-drift` répond à deux questions :

— **Le modèle tient-il ?** Sur les 60 derniers jours, les pannes passées sont connues : on les compare aux alertes qui les précédaient, avec la même métrique qu'à l'entraînement.

— **Les capteurs dérivent-ils ?** Les 30 derniers jours sont comparés aux mêmes jours un an plus tôt (indice de stabilité de population, PSI) : la météo est saisonnière, comparer avec le mois précédent signalerait l'Harmattan comme une dérive.

Une dérive est un signal à examiner, pas un réentraînement automatique.

7 Limites

1. Les données sont simulées : les mécanismes sont plausibles, mais les résultats restent à confirmer sur de vrais capteurs.
2. Les pannes électriques et aléatoires n'ont pas de signe avant-coureur et ne sont pas apprises.
3. Moins d'une alerte sur quatre précède une panne : le modèle n'est rentable que tant qu'une inspection coûte moins d'environ 5 700 FCFA.
4. La cause probable désigne une famille physique, pas un diagnostic du mode de panne.

Glossaire

Terme	Définition
Calibration	Ajustement des scores du modèle pour qu'ils se lisent comme des probabilités
Champion	Version du modèle servie en production (alias MLflow `@champion`)
Épisode d'alerte	Suite d'alertes consécutives sur une machine, redécoupée toutes les 24 h : une intervention
GMAO	Gestion de maintenance assistée par ordinateur : compteurs d'heures et historique des interventions
Harmattan	Vent sec chargé de poussière saharienne, de décembre à mars en Afrique de l'Ouest
MTBF, MTTR	Temps moyen de marche entre deux pannes ; temps moyen de réparation
PSI	Population Stability Index : écart entre deux distributions d'une même variable
Recall événementiel	Part des pannes précédées d'au moins une alerte dans les 120 h
SBEE	Société béninoise d'énergie électrique, dont les délestages coupent le courant
SHAP	Méthode qui attribue à chaque variable sa contribution à une prédiction
TWF, OSF, HDF, PWF, RNF	Modes de panne : usure de l'outil, surcharge mécanique, surchauffe, électrique, aléatoire